

Parkinson Hastalığı Sınıflandırma Veri Kümesi

Kişiler:

C. Okan Sakar, Gorkem Serbes, Aysegul Gunduz, Hunkar C. Tunc, Hatice Nizam, Betul Erdogdu Sakar , Melih Tutuncu , Tarkan Aydin , M. Erdem Isenku, Hulya Apaydin

Amaç:

Bu çalışmanın amacı parkinson hastalığının tanısının koyulmasında uzaktan görüntüleme sistemi geliştirilmesidir. Bu amaç doğrultusunda kişilerden alınan ses sinyalinin parkinson hastası olup olmadığı tahmin edilmektedir. Alınan ses sinyali, çeşitli sinyali işleme teknikleri kullanılarak sayısallaştırılmıştır. Bu sayısallaştırma sonucunda 6 kategoride toplam 755 farklı özellik elde edilmiştir. Özellik kategorileri ve kısa açıklamaları tablo 1’de verilmiştir.

Tablo 1. Özellik kümeleri

Özellik Kümesi	Açıklama	Özellik Sayısı
Temel Özellikler	Bir ses sinyalinin temel özelliklerini içeren özellikler bu kategoride verilmiştir. Frekans bilgisi, osilasyon ve salınım özellikleri.	21
Zaman frekans özellikleri	Yoğunluk, akustik ve bant genişliği ile ilgili özellikler kümesi	11
Mel Frekans Kepstral Katsayısı	Kısa süreli güç spektrumu hakkında bilgi içeren özellik kümesi	84
Dalgacık Dönüşümü	Dalgacık Dönüşümü sonucunda elde edilen özellik kümesi (F0)	182
Ses Kıvrımları özellikleri	Ses oluşumu sırasında dudak ve boğazda meydana gelen olay bilgilerini içeren özellikler	22

Ayarlanabilir Dalgacık (TQWT)	Q-faktör Dönüşümü	Ayrık ve Ayarlanabilir osilatör davranışına sahip DD	432
-------------------------------	-------------------	------------------------------------------------------	-----

Elde edilen tüm veriler ön işleme adımında standartlaştırılarak özellik seçimi yöntemine verilmektedir. Bu adımda en uygun özellikler belirlenmekte ve makine öğrenmesi yöntemine giriş olarak uygulanmaktadır. Özellik seçimi aşamasında kullanılan minimum fazlalık maksimum uygunluk (mRMR) filtresi kullanılarak en önemli 50 özellik 3 farklı kombinasyon için Tablo 2’deki gibi seçilmiştir. İlk deneyde TQWT özellikleri, özellik kümesinden çıkartılmıştır. İkinci deneyde MFCC özellikleri çıkartılmış ve son deneyde ise tüm özellikler kullanılmıştır.

Tablo 2. Özellik Seçimi

Average distribution of the top-50 features selected by the mRMR filter.

	All feature subsets except TQWT	All feature subsets except MFCC	All feature subsets
Baseline (n = 26)	5	5	4
Intensity (n = 3)	1	1	0
Bandwidth + Formant (n = 8)	5	2	2
MFCC (n = 84)	27	–	10
WT applied to F_0 (n = 182)	4	1	1
Vocal Fold (n = 22)	8	4	3
TQWT (n = 432)	–	37	30

Elde edilen başarı oranları Tablo 2’de verilmiştir. Başarı değerleri LOOCV çapraz doğrulama yöntemi kullanılarak elde edilmiştir. Tablo 2’ye göre en yüksek başarı tüm özellik kümelerinin birlikte SVM yöntemi ve RBF çekirdeği ile birlikte kullanıldığı deneyde elde edilmiştir.

Tablo 3. Makine öğrenmesi yöntemlerinin sonuçları

	All feature subsets except TQWT			All feature subsets except MFCC			All feature subsets		
	Accuracy	F1-Score	MCC	Accuracy	F1-Score	MCC	Accuracy	F1-Score	MCC
Naive Bayes	0.65	0.67	0.29	0.81	0.81	0.51	0.83	0.83	0.54
Logistic regression	0.81	0.79	0.45	0.83	0.82	0.51	0.85	0.84	0.57
k-NN	0.82	0.79	0.48	0.84	0.82	0.53	0.85	0.82	0.56
Multilayer perceptron	0.83	0.81	0.50	0.81	0.80	0.46	0.84	0.83	0.54
Random Forest	0.79	0.78	0.40	0.83	0.82	0.51	0.85	0.84	0.57
SVM (Linear)	0.81	0.80	0.46	0.84	0.83	0.54	0.83	0.82	0.52
SVM (RBF)	0.83	0.81	0.50	0.83	0.81	0.50	0.86	0.84	0.59
Average	0.79	0.77	0.43	0.83	0.82	0.51	0.84	0.83	0.55
Std. Dev.	0.07	0.05	0.08	0.01	0.01	0.03	0.01	0.01	0.02
Ensemble with voting	0.81	0.80	0.46	0.85	0.84	0.57	0.85	0.84	0.58
Ensemble with stacking	0.82	0.81	0.49	0.83	0.81	0.52	0.84	0.82	0.55

Rafet DURGUT